

百度广告点击率预测与投放优化分析实习项目大纲

一、项目背景

百度作为全球领先的中文搜索引擎与营销科技平台，搜索广告（凤巢系统）、信息流广告构成了集团核心商业体系，海量广告曝光、用户点击、转化行为数据中，蕴含着用户偏好、广告价值、投放效率等核心商业信息。点击率（CTR）预估是广告精准投放、流量价值最大化的核心技术底座，数据驱动已成为百度广告投放优化、用户体验升级、客户服务提效的核心竞争力。

本实习项目聚焦百度广告核心业务场景，以数据工程能力培养、广告特征深度挖掘、多模型CTR预估建模、业务价值转化为核心目标，通过系统化的数据分析全流程、工程化落地规范及算法建模任务，全面提升在大数据处理、特征工程、模型构建与评估、业务洞察等方面的核心技能，匹配百度数据分析岗位的能力要求与工作范式。

二、项目整体核心任务

本项目对标百度凤巢搜索广告与信息流广告的真实业务流程，基于千万级广告曝光-点击数据集，完成从数据治理、特征挖掘、模型建模到业务落地的全链路数据分析工作，最终实现以下核心目标：

- 完成千万级广告行为数据的工程化治理，搭建标准化的数据处理流程与质量管控体系，实现数据的高效存储与查询
- 构建覆盖时间、广告位、媒体内容、用户设备四大维度的全量特征体系，完成多维度探索性分析，定位广告转化的核心影响因素与流失节点
- 搭建传统机器学习与深度学习结合的多模型CTR预估体系，完成模型调优、性能对比与融合优化，输出高精度的广告点击率预测能力
- 基于数据分析结论与模型预测结果，提炼广告投放优化、定向策略调整的可落地建议，设计模拟A/B测试方案并量化预期收益
- 沉淀可复用的广告数据分析与建模工具包，输出完整的项目报告与汇报材料，形成标准化的广告数据分析方法论

三、数据概况

3.1 数据集基本信息

- 数据规模：约4000万条广告曝光-点击记录，覆盖10天连续投放周期
- train - 训练集。10天的点击数据，按时间顺序排列。未点击和点击的样本根据不同策略进行抽样。
- test - 测试集。1天的广告数据，用于测试你的模型预测。

- sampleSubmission.csv - 正确格式的示例文件。

3.2 核心字段说明

字段名	数据类型	详细说明
id	string	广告曝光记录唯一标识
click	int	目标变量，标识用户是否点击广告：0=未点击，1=点击
hour	string	广告曝光时间，格式为YYMMDDHH，精确到小时
banner_pos	int	广告在页面中的展示位置编码
site_id	string	广告投放站点的唯一标识
site_category	string	广告投放站点的内容类目
app_id	string	广告投放应用的唯一标识
app_category	string	广告投放应用的内容类目
device_type	int	用户访问设备类型编码
device_model	string	用户设备型号
C1-C21	string	21个匿名类别特征，覆盖广告素材、用户属性、上下文场景等维度

四、阶段任务与交付成果

第一阶段：数据工程体系搭建与理论储备

核心目标

完成大数据处理环境与工程化管理体系搭建，建立互联网广告CTR预估的理论基础，实现数据全流程自动化处理与质量管控。

具体任务

- 工程化环境与版本管理搭建** 配置Python大数据分析环境（Pandas、Dask、NumPy、PyArrow），针对千万级数据规模优化内存分配与计算资源调度；搭建Git版本管理体系，制定Commit Message规范与main/dev/feature三级分支管理策略，所有代码、文档、中间结果按目录规范同步至仓库；设计模块化项目目录结构，实现数据层、代码层、文档层、结果层的完全解耦。
- 领域文献调研与技术栈储备** 精读3-5篇广告CTR预估经典论文（参考论文：《Wide & Deep Learning for Recommender Systems》《Deep Interest

Network for CTR Prediction》《Field-aware Factorization Machines for CTR Prediction》等), 梳理核心算法思想与广告特征工程范式; 调研行业主流广告数据分析技术方案, 对比不同工具与模型在大规模广告数据场景下的优劣与适用场景。

- 3. 千万级数据加载与全流程清洗** 完成数据集的获取与合规性校验, 设计分块读取+并行处理方案, 解决单节点内存溢出问题; 执行多维度数据清洗: 基于业务规则与IQR/3 σ 法则处理异常值, 基于曝光记录唯一标识去重, 统一时间格式并校验时间有效性; 开发自动化数据质量校验脚本, 实现数据完整性、一致性、唯一性的批量检测, 生成可追溯的质量报告。
- 4. 数据预处理与中间表构建** 完成数据类型压缩(字符串转类别型、数值型精度适配)与非必要字段筛选, 将数据转换为Parquet格式提升读写效率; 构建广告位、媒体站点、用户设备、时间四个维度的基础聚合中间表, 为后续特征工程做预计算。

交付成果

- 符合规范的Git项目仓库(含完整目录结构与提交记录)
- 领域文献调研笔记
- 数据处理自动化脚本集(加载、清洗、质量校验、格式转换)
- 数据处理报告(含处理逻辑、质量评估结果、中间表设计说明)
- 预处理后的标准化数据集(Parquet格式)

第二阶段：深度特征工程与多维度探索性分析

核心目标

构建多维度、高区分度的广告特征体系, 通过全面的探索性数据分析挖掘广告转化规律与特征关联, 为后续CTR预估建模提供高质量输入。

具体任务

- SQLite数据库搭建与SQL基础分析** 设计符合第三范式的SQLite数据库表结构, 创建广告行为主表、广告位维度表、媒体维度表、设备维度表、时间维度表; 编写批量数据导入脚本, 将预处理后的Parquet格式数据高效导入SQLite数据库, 为高频查询字段建立索引优化性能; 掌握SQL核心语法, 完成基础数据统计分析: 总曝光量与总点击率统计、各广告位点击率对比、时段投放趋势查询、高转化媒体站点排名; 实现复杂SQL查询: 分维度转化率计算、广告投放漏斗分析、用户设备分群统计、媒体复投率分析; 建立Python与SQLite的交互接口, 实现SQL查询结果与Pandas DataFrame的无缝转换。
- 全维度特征体系构建**
 - 基础特征扩展: 新增时间特征(小时、工作日/周末、投放时段等级)、广告位特征(曝光量级、历史点击率、位置竞争度)、媒体特征(站点热度、类目转化能

- 力)、设备特征(设备类型占比、网络环境转化率)、统计特征(用户历史点击率、广告历史曝光点击量)
- 交叉特征挖掘: 构建广告位×时段、媒体类目×设备类型、站点×广告位等高价值交叉组合特征; 通过目标编码提取高维类别特征的转化信息
 - 业务导向特征: 基于历史投放表现构建广告价值评分, 设计分维度转化效率特征, 构建用户活跃度与广告偏好强度得分
3. **特征预处理与有效性验证** 完成数值型特征标准化/归一化、类别型特征编码(Target Encoding替代独热编码处理高维类目特征), 针对稀疏特征实现预嵌入处理; 通过相关性分析、互信息法、方差阈值法进行特征筛选, 剔除冗余特征与低区分度特征; 验证特征与目标变量(广告是否被点击)的相关性, 输出特征重要性预评估报告。
4. **多维度探索性数据分析**
- 基础投放分析: 统计整体曝光与点击分布、日/时段投放趋势、各广告位流量占比, 识别高转化时段与高价值广告位
 - 转化效率分析: 拆解广告从曝光到点击的转化链路, 定位低转化广告位与媒体类目
 - 媒体与类目分析: 挖掘高转化媒体站点与热门内容类目, 分析不同类目广告的转化差异与竞争度
 - 用户设备分群分析: 基于设备类型、网络环境划分用户群体, 对比不同群体的点击偏好与转化效率
 - 时间维度分析: 对比工作日与周末、高峰与平峰时段的广告投放效果与点击率差异

交付成果

- SQLite数据库文件(含完整表结构与索引)
- SQL查询脚本集(基础统计、转化分析、分群统计等)
- Python-SQLite交互工具类
- 完整的特征字典(含特征定义、计算逻辑、预处理方法、区分度评估)
- 特征工程脚本集与预处理后的特征数据集
- 特征有效性评估报告(含相关性热力图、重要性排序)
- 探索性数据分析报告(含至少8种核心可视化图表)
- 核心数据洞察总结(含广告投放规律、转化瓶颈、投放优化建议)

第三阶段: 多模型建模与性能优化

核心目标

完成传统机器学习与深度学习模型的全流程构建与调优, 对比不同模型的CTR预估性能差异, 深入分析模型可解释性, 探索模型融合方案提升预测效果, 匹配百度广告精准投放的业务场景。

具体任务

- 1. 样本构建与数据集划分** 明确目标变量定义（单条广告曝光记录是否产生点击行为），构建正负样本集；采用分层抽样按7:2:1划分训练集、验证集、测试集，保证各数据集分布一致性；对比SMOTE过采样、欠采样与类别权重调整三种方案，解决广告点击样本占比低的类别不平衡问题。
- 2. 传统机器学习模型构建与调优** 实现逻辑回归、XGBoost、LightGBM三种分类模型，完成模型初始化与基础训练；采用Optuna自动超参数调优框架，优化模型关键参数，以AUC为核心评估指标；对比三种传统模型的性能（AUC、准确率、召回率、F1分数、LogLoss），分析各自的优势场景与局限性。
- 3. 深度学习CTR模型构建与优化** 实现经典CTR深度学习模型（Wide&Deep、DIN深度兴趣网络），完成稀疏特征嵌入与模型输入构建；优化模型架构：调整嵌入维度、隐藏层单元数、Dropout比例，引入注意力机制提升特征交互提取能力；采用学习率衰减、早停（Early Stopping）策略防止过拟合，对比不同深度学习模型与传统模型的性能差异。
- 4. 模型融合与可解释性分析** 设计Stacking模型融合方案，融合树模型与深度学习模型的预测结果，进一步提升整体CTR预估性能；深入分析模型可解释性：基于特征系数解释逻辑回归，基于SHAP值解释树模型与深度学习模型，识别影响用户点击决策的核心特征；分析模型预测错误样本的特征，总结模型在冷启动广告、长尾媒体场景下的不足。
- 5. 业务落地模拟设计** 基于模型预测结果，设计模拟A/B测试方案，明确实验分组、核心评估指标（点击率、eCPM、流量利用率）与实验周期；提出基于模型的广告投放优化、定向策略调整、广告位流量分配建议，量化预期业务收益（CTR提升幅度、广告价值提升比例）。

交付成果

- 单模型性能评估报告
- 模型融合方案与性能对比报告
- 模型可解释性分析报告（含SHAP可视化结果）
- 模拟A/B测试方案与业务落地建议

第四阶段：成果沉淀与项目复盘

核心目标

完成项目成果的系统化整理与可复用封装，进行全面的项目复盘，提升技术总结与表达能力。

具体任务

- 1. 代码工程化封装** 将数据处理、特征工程、模型训练、预测推理等模块封装为可复用的Python工具包，编写API文档与使用示例；完善代码注释与单元测试，提升代码的可读性与健壮性。

2. **项目文档与汇报材料撰写** 撰写完整的项目总报告，涵盖项目背景、数据概况、技术方案、实验结果、核心洞察与业务建议；制作项目汇报PPT与技术分享PPT，梳理项目核心亮点与技术难点。
3. **项目复盘与总结** 复盘项目全流程，总结数据处理、特征工程、建模过程中遇到的问题与解决方案；分析项目存在的局限性，提出后续优化方向（如引入Transformer架构的CTR模型、扩充用户行为序列特征、增加实时投放特征等）。
4. **成果提交与展示** 整理所有项目成果，同步至Git仓库main分支，生成版本发布记录；进行项目成果汇报与技术分享。

交付成果

- 可复用的广告CTR分析Python工具包（含API文档与使用示例）
- 完整的项目总报告（含所有分析与建模结果）
- 项目汇报PPT与技术分享PPT
- 最终Git仓库